

TIPE: Modélisation des résultats des matchs de football

Application à la Premier League

OUNZAR Aymane - n° 18290

LM6E

2024/2023

- 1 Introduction :
 - Modèle de base :
- 2 Détermination des paramètres :
 - Maximum de vraisemblance
 - Maximum de vraisemblance pondéré
- 3 Dépendance :
 - Y a-t-il dépendance entre les variables aléatoires?
 - Les copules
- 4 Les modèles :
 - Premières vérifications
- 5 Comparaison
 - Critère d'Akaike
 - Pariage
 - Résultats
- 6 Commentaires :
- 7 Annexe



Modèle de base :

Détails du modèle (Modèle 0) :

- Deux équipes H et A

Modèle de base :

Détails du modèle (Modèle 0) :

- Deux équipes H et A
- L'équipe H joue sur son terrain et A est visiteuse.

Modèle de base :

Détails du modèle (Modèle 0) :

- Deux équipes H et A
- L'équipe H joue sur son terrain et A est visiteuse.
- $X_H \sim P(\lambda_H)$ et $X_A \sim P(\lambda_A)$ où $\lambda_H = \exp(\alpha_H + \beta_A + \gamma)$ et $\lambda_A = \exp(\alpha_A + \beta_H)$, γ représente l'avantage du terrain

Modèle de base :

Détails du modèle (Modèle 0) :

- Deux équipes H et A
- L'équipe H joue sur son terrain et A est visiteuse.
- $X_H \sim P(\lambda_H)$ et $X_A \sim P(\lambda_A)$ où $\lambda_H = \exp(\alpha_H + \beta_A + \gamma)$ et $\lambda_A = \exp(\alpha_A + \beta_H)$, γ représente l'avantage du terrain
- X_H et X_A sont considérés indépendants.

Modèle de base :

Détails du modèle (Modèle 0) :

- Deux équipes H et A
- L'équipe H joue sur son terrain et A est visiteuse.
- $X_H \sim P(\lambda_H)$ et $X_A \sim P(\lambda_A)$ où $\lambda_H = \exp(\alpha_H + \beta_A + \gamma)$ et $\lambda_A = \exp(\alpha_A + \beta_H)$, γ représente l'avantage du terrain
- X_H et X_A sont considérés indépendants.
- les coefficients $\alpha_H, \beta_A, \alpha_A, \beta_H$ change avec le temps .

Pourquoi Poisson :

Approximation :

Chaque fois une équipe a le ballon, elle va essayer de marquer un but.

On note par p la probabilité que le but va être marqué

Puisqu'une équipe peut avoir plusieurs occasions pendant un match pour marquer, donc le nombre de buts marqués par l'équipe est binomial.

Pourquoi Poisson :

Approximation :

Chaque fois une équipe a le ballon, elle va essayer de marquer un but.
On note par p la probabilité que le but va être marqué
Puisqu'une équipe peut avoir plusieurs occasions pendant un match pour marquer, donc le nombre de buts marqués par l'équipe est binomial.

Puisque p est très petit et le nombre de fois où l'équipe a le ballon est grand. On peut approcher la loi Binomiale par la loi de poisson.

Maximum de vraisemblance :

On dispose d'un échantillon de N matchs $(x_1, y_1), \dots, (x_N, y_N)$ où x_k est le nombre de buts marqués par l'équipe à domicile dans un match k et y_k est le nombre de buts marqués par l'équipe visiteuse pendant le match k .

Estimateur de vraisemblance :

Il est défini par :

$$\mathcal{L}(\alpha, \beta, \gamma) = \prod_{k \in \mathcal{A}} P(X_H = x_k, X_A = y_k)$$

où $\mathcal{A}$ est l'ensemble des matchs

Maximum de vraisemblance :

On cherche les valeurs des paramètres qui maximise l'estimateur de vraisemblance, $\mathcal{L}(\alpha, \beta, \gamma)$ ce qui est équivalent à maximiser :

$$\ell(\alpha, \beta, \gamma) = \ln(\mathcal{L}(\alpha, \beta, \gamma))$$

Maximum de vraisemblance pondéré :

La fonction du maximum de vraisemblance pondérée est donc donnée par :

$$\tilde{\ell}(\alpha, \beta, \gamma, \tau) = \sum_{k \in \mathcal{A}_t} \ln(P(X_H = x_k, X_A = y_k)) \Phi(t - t_k)$$

avec :

- $\mathcal{A}_t$ est l'ensemble des matchs ayant lieu avant le jour t
- t_k est le jour du match k
- t est le jour de détermination des paramètres

Choix de Φ :

On peut supposer que la décroissance est exponentielle :

$$\Phi : t \longmapsto e^{-\theta t}$$

Détermination de θ :

On ne peut pas déterminer la valeur de θ en utilisation la méthode du maximum de vraisemblance car :

$$\lim_{\theta \rightarrow +\infty} \tilde{\ell}(\alpha, \beta, \gamma, \theta) = 0$$

quelles que soient les données qu'on utilise.

Ordre de grandeur de θ :

On va utiliser les données des années 2021/2022 et 2022/2023 lors de l'estimation des paramètres du modèle.

La durée caractéristique τ est de l'ordre de grandeur de

$$365 \times 2 = 730 \text{ jours}$$

Alors l'ordre de grandeur de $\theta = \frac{1}{\tau}$ est : 10^{-3}

Ordre de grandeur de θ :

On va utiliser les données des années 2021/2022 et 2022/2023 lors de l'estimation des paramètres du modèle.

La durée caractéristique τ est de l'ordre de grandeur de

$$365 \times 2 = 730 \text{ jours}$$

Alors l'ordre de grandeur de $\theta = \frac{1}{\tau}$ est : 10^{-3}

$$\theta \in \{0.001, 0.002, 0.003, 0.004, 0.005, 0.006, 0.007, 0.008, 0.009\}$$

Choix de θ :

Pour chaque θ on détermine les valeurs de α, β et γ qui maximisent $\tilde{\ell}(\alpha, \beta, \gamma, \theta)$. On garde la valeur de θ pour laquelle :

$$S(\theta) = \sum_{k=1}^N (\delta_k^H \log p_k^H + \delta_k^A \log p_k^A + \delta_k^D \log p_k^D + \gamma_k^{O2.5} \log p_k^{O2.5} + \gamma_k^{U2.5} \log p_k^{U2.5})$$

est maximale.

Dépendance :

Soit $(x_1, y_1), (x_2, y_2), \dots, (x_n, y_n)$ un ensemble d'observations des variables jointes X et Y tel que les valeurs des (x_i) et (y_i) sont uniques.

Définition :

On dit qu'un pair (x_i, y_i) et (x_j, y_j) est **concordant** si $x_i < x_j$ et $y_i < y_j$ ou si $x_i > x_j$ et $y_i > y_j$

Définition :

On dit qu'un pair (x_i, y_i) et (x_j, y_j) est **discordant** si $x_i < x_j$ et $y_i > y_j$ ou si $x_i > x_j$ et $y_i < y_j$

Tau de kendall:

Le Tau de kendall mesure la corrélation de rang entre deux variables. Il est défini ainsi :

Le tau de Kendall est alors défini comme :

$$\tau_d = \frac{(\text{nombre de paires concordantes}) - (\text{nombre de paires discordantes})}{\frac{1}{2} \cdot n \cdot (n - 1)}$$

Tau de kendall:

Le Tau de kendall mesure la corrélation de rang entre deux variables. Il est défini ainsi :

Le tau de Kendall est alors défini comme :

$$\tau_d = \frac{(\text{nombre de paires concordantes}) - (\text{nombre de paires discordantes})}{\frac{1}{2} \cdot n \cdot (n - 1)}$$

D'après les données des années 2011 à 2024, j'ai estimé la valeur

$$\tau_d = -0.0227$$

Définition :

Soit (X, Y) un vecteur aléatoire à valeurs dans $\mathbb{R}^2$. La loi de (X, Y) est caractérisée par :

$$\forall (x, y) \in \mathbb{R}^2, F(x, y) = P(X \leq x, Y \leq y).$$

F est la fonction de répartition bivariable de (X, Y) . Lois marginales de (X, Y) sont décrites par :

$$F_1(x) = P(X \leq x) = \lim_{y \rightarrow +\infty} F(x, y) = F(x, +\infty),$$

$$F_2(y) = P(Y \leq y) = \lim_{x \rightarrow +\infty} F(x, y) = F(+\infty, y).$$

Définition

Une copule bivariable est une fonction $C : \mathbb{I}^2 \rightarrow \mathbb{I}$ telle que :

- pour tout $u \in \mathbb{I}$, $C(u, 0) = C(0, u) = 0$;
- pour tout $u \in \mathbb{I}$, $C(u, 1) = C(1, u) = u$;
- pour tout $u_1, u_2, v_1, v_2 \in \mathbb{I}$ tels que $u_1 \leq u_2$ et $v_1 \leq v_2$, on a :

$$C(u_2, v_2) - C(u_2, v_1) - C(u_1, v_2) + C(u_1, v_1) \geq 0.$$

Théorème de Sklar (Admis) :

- 1 Si C est une copule, si F_1 et F_2 sont deux fonctions de répartition, alors $F(x, y) = C(F_1(x), F_2(y))$ est une fonction de répartition bivariée, ayant F_1 et F_2 pour marginales.
- 2 Soit F une fonction de répartition bivariée de marginales F_1 et F_2 . Il existe une copule C telle que pour tout $(x, y) \in \mathbb{R}^2$:

$$F(x, y) = C(F_1(x), F_2(y)).$$

En 2009, Ian McHale et Phil Scarf ont trouvé que la structure de dépendance entre X_H et X_A peut être modélisée par la copule de Frank.

Copule de Frank :

$$C(u, v)_\tau = -\frac{1}{\tau} \ln \left(1 + \frac{(e^{-\tau u} - 1)(e^{-\tau v} - 1)}{e^{-\tau} - 1} \right)$$

- On note F_H la fonction de répartition de la loi marginale X_H .
- On note F_A la fonction de répartition de la loi marginale X_A .
- On note F la fonction de répartition bi-dimensionnelle du couple (Y_H, Y_A) .

- D'après le théorème de Sklar:

$$F(x_H, x_A) = C_\tau(F_H(x_H), F_A(x_A)) \\ = \frac{-1}{\tau} \ln \left(1 + \frac{(e^{-\tau F_H(x_H)} - 1)(e^{-\tau F_A(x_A)} - 1)}{e^{-\tau} - 1} \right)$$

- Dans ce cas, la probabilité que H marque x_H buts et que A marque x_A buts est :

$$P_\tau(X_H = x_H, X_A = x_A) = C_\tau(F_H(x_H), F_A(x_A)) - \\ C_\tau(F_H(x_H - 1), F_A(x_A)) - \\ C_\tau(F_H(x_H), F_A(x_A - 1)) + \\ C_\tau(F_H(x_H - 1), F_A(x_A - 1))$$


Échantillon :

On va appliquer le modèle sur les matchs des 14 **dernières semaines**, les **premiers 24 semaines** seront utilisées pour l'entraînement du modèle.


Les modèles :

	Estimateur de vraisemblance pondéré :	Copule :
Modèle 0	NON	NON
Modèle 1	OUI	NON
Modèle 2	OUI	OUI


Valeur de θ modèle 1 :




Valeur de θ modèle 1 :



Valeur de θ modèle 2




Valeur de θ modèle 2



Observations :

Équipe	α	Classement	$-\beta$	Classement
Arsenal	1.4365	2	1.1458	2
Aston Villa	1.1698	6	0.8325	5
Bournemouth	0.8327	14	0.5657	17
Brentford	0.9814	10	0.7428	13
Brighton	1.0973	7	0.7566	11
Burnley	0.6509	18	0.5255	18
Chelsea	1.0640	8	0.7843	8
Crystal Palace	0.7585	17	0.7459	12
Everton	0.6315	19	0.8010	6
Fulham	0.9480	13	0.7588	10
Liverpool	1.3674	3	1.1350	3
Luton Town	0.9813	11	0.4111	19
Manchester City	1.4656	1	1.2374	1
Manchester Utd	1.0160	9	0.8468	4
Newcastle Utd	1.2834	4	0.7945	7
Nott'ham Forest	0.7849	15	0.6090	16
Sheffield Utd	0.5668	20	0.2007	20
Tottenham	1.2370	5	0.7368	14
West Ham	0.9561	12	0.6471	15
Wolves	0.7709	16	0.7717	9

Observations :



Observations :

Proposition (Admise) :

Si τ_d est Tau de kendall et

$$\tau_d = 1 - 4\tau^{-1}(1 - \mathbf{D}_1(\tau))$$

où : $\mathbf{D}_n$ est la fonction de Debye définie par :

$$D_n(x) = \frac{n}{x^n} \int_0^x \frac{t^n}{e^t - 1} dt$$

En moyenne $\tau = -0.32$ donc $\tau_d = -0.035$

Définition :

Le critère d'information d'Akaike :

Le critère d'information d'Akaike s'écrit comme suit :

$$AIC = 2k - 2\ln(L)$$

où k est le nombre de paramètres à estimer du modèle et L est le maximum de la fonction de vraisemblance du modèle. On choisit alors le modèle avec le critère d'information d'Akaike le plus faible.

Résultats :

Modèle	Paramètres :	ℓ	AIC
Modèle 0	41	-441.120	964.240
Modèle 1	42	-438.110	960.22
Modèle 2	43	-438.833	963.666

Résultats :

Modèle	Paramètres :	ℓ	AIC
Modèle 0	41	-441.120	964.240
Modèle 1	42	-438.110	960.22
Modèle 2	43	-438.833	963.666

Modèle	Match gagné par équipe à domicile	match null	match gagné par équipe visiteuse	Total
Modèle 0	55/65	0/34	29/44	84/143
Modèle 1	49/65	0/34	34/44	83/143
Modèle 2	53/65	0/34	30/44	83/143

Résultats :

Modèle	Plus que 2.5 buts	Moins que 2.5 buts	Total
Modèle 0	71/92	15/51	86/143
Modèle 1	76/92	12/51	88/143
Modèle 2	81/92	11/51	92/143

- Marché 1X2
- Marché $O/U2.5$

Pour chaque match, on estime les paramètres des équipes, on calcule les probabilités et on décide si on va parier ou non

Critère de pariage :

On ne parie que lorsque :

$$E(A) = P(A) \times (b + 1) - 1 > t$$

où :

- A est un événement
- $P(A)$ est la probabilité de l'événement A
- b est la cote nette reçue sur le pari

$$\frac{1}{b + 1}$$

peut être interprétée comme la probabilité de l'événement A estimée par le 'Bookmaker'.

Démarche :

- Détermination de la probabilité des événements par notre modèle

Démarche :

- Détermination de la probabilité des événements par notre modèle
- Calcul de la quantité $E(A)$

Démarche :


- Détermination de la probabilité des événements par notre modèle
- Calcul de la quantité $E(A)$
- Si $E(A) > t$ on parie avec la fraction f de nos fonds

Démarche :


- Détermination de la probabilité des événements par notre modèle
- Calcul de la quantité $E(A)$
- Si $E(A) > t$ on parie avec la fraction f de nos fonds
- Sinon on ne parie pas

Modèle 0 :

Profit : 1X2 marché




Nombre de paris



Profit : O/U 2.5 marché




Nombre de paris




Modèle 0 :


Profit : 1X2 marché




Nombre de paris



Profit : O/U 2.5 marché



Nombre de paris




Modèle 1 :


Profit : 1X2 marché




Nombre de paris



Profit : O/U 2.5 marché




Nombre de paris




Modèle 1 :


Profit : 1X2 marché




Nombre de paris



Profit : O/U 2.5 marché




Nombre de paris




Modèle 2 :


Profit : 1X2 marché




Nombre de paris



Profit : O/U 2.5 marché




Nombre de paris




Modèle 2 :

Profit : 1X2 marché




Nombre de paris



Profit : O/U 2.5 marché



Nombre de paris



Récapitulatif :

θ	Modèle 0	Modèle 1	Modèle 2
Marché 1X2 :			
Profit positif :	OUI	OUI	OUI
Profit maximal :	47.5	87.5	7.5
Nombre de paris :	9	14	3
Valeur de t qui maximise le profit :	1.62	1.55	1.64
Marché O/U 2.5 :			
Profit positif :	OUI	OUI	OUI
Profit maximal :	84.3	54.3	60.49
Nombre de paris :	10	13	72
Valeur de t qui maximise le profit :	1.46	1.329	1.05

Commentaires :

- Les trois modèles étaient capables de bien Prévoir les résultats des matchs.

Commentaires :

- Les trois modèles étaient capables de bien Prévoir les résultats des matchs.
- Les trois modèles avaient presque la même performance quant à la prédiction qui gagne le match.

Commentaires :

- Les trois modèles étaient capables de bien Prévoir les résultats des matchs.
- Les trois modèles avaient presque la même performance quant à la prédiction qui gagne le match.
- Le modèle 2 était plus performant quant à prédire si les matchs vont finir par plus ou moins de 2.5 buts.

- Les trois modèles étaient capables de bien Prévoir les résultats des matchs.
- Les trois modèles avaient presque la même performance quant à la prédiction qui gagne le match.
- Le modèle 2 était plus performant quant à prédire si les matchs vont finir par plus ou moins de 2.5 buts.
- Lors des parages, les trois modèles étaient capables d'aboutir à des profits positifs.

- Les trois modèles étaient capables de bien Prévoir les résultats des matchs.
- Les trois modèles avaient presque la même performance quant à la prédiction qui gagne le match.
- Le modèle 2 était plus performant quant à prédire si les matchs vont finir par plus ou moins de 2.5 buts.
- Lors des parages, les trois modèles étaient capables d'aboutir à des profits positifs.
- Le modèle 1 est suffisant.

Merci pour votre
attention

Pour des variables aléatoires à valeurs dans $\mathbb{N}$ on trouve

$$\begin{aligned}P(X = x, Y = y) &= P(X \leq x, Y \leq y) - P(X \leq x, Y < y) \\&= P(X \leq x, Y \leq y) - P(X \leq x, Y < y) \\&\quad + P(X < x, Y \leq y) - P(X < x, Y < y) \\&= F(x, y) - F(x, y - 1) - F(x - 1, y) + F(x - 1, y - 1)\end{aligned}$$